## Atelier 3 – Affichage web du texte

Atelier "Créer une édition scientifique numérique"

Floriane Chiffoleau Ingénieure en humanités numériques à l'ObTIC DataLab - BNF (Salle 70) 16 mai 2025



### **Sommaire**

- Publier son corpus : Partage ≠ Affichage
- Publier son corpus : Partage
- Publier son corpus : Affichage
- ☐ Éléments nécessaires à l'affichage
- → Panorama de divers moyens de publication
- Ressources

# **PUBLIER SON CORPUS:**PARTAGE ≠ AFFICHAGE

## Partage ≠ Affichage

- Données brutes = partage
  - Mettre à disposition le corpus pour réutilisation
  - Pérenniser et identifier
     numériquement pour citation
     son corpus
  - Centraliser ses documents

- Données enrichies = affichage
  - Observer le texte de manière lisible pour l'humain
  - **☐** Faire ressortir l'enrichissement
  - Exploiter les liens entre les documents

## **PUBLIER SON CORPUS: PARTAGE**

## Partage de données brutes : Exemples

- Vérités de terrain pour la reconnaissance automatique de texte (ATR) :
   HTR-United pour les métadonnées, GitHub pour les fichiers XML et les images, Zenodo pour les modèles
- ☐ Éditions scientifiques numériques, projet DAHN et EHRI : GitHub pour les fichiers XML, Zenodo ou GitHub pour les modèles, Nakala pour les images





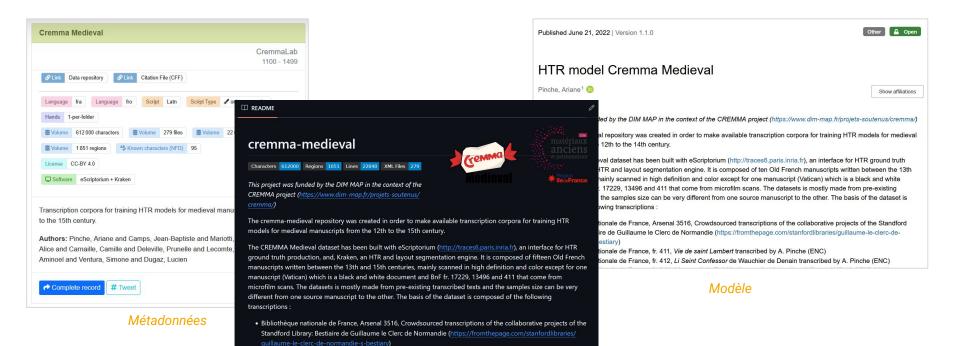






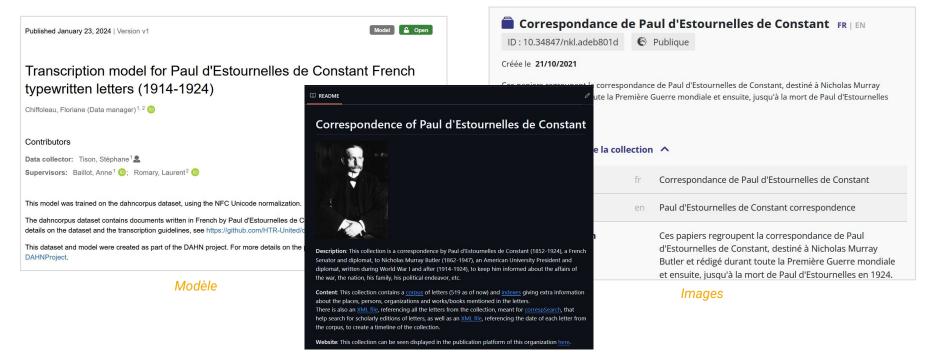


## Partage de données brutes: HTR-United

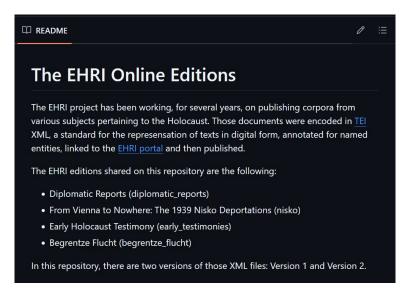


Images et XML

## Partage de données enrichies : Projet DAHN



## Partage de données enrichies : Projet EHRI





Fichiers XML et modèle

**Images** 

## **PUBLIER SON CORPUS: AFFICHAGE**

## Affichage de données enrichies : Se poser les bonnes questions

- ☐ Type de contenu : Le contenu est-il statique ou doit-il être régulièrement mis à jour ?
- Niveau d'interactivité : Souhaitez-vous que l'utilisateur puisse interagir avec le contenu (cliquer, survoler, filtrer) ?
- Adaptabilité : L'affichage doit-il être totalement responsive pour s'adapter aux mobiles, tablettes et ordinateurs ?
- Style visuel: Quel est le style esthétique recherché (minimaliste, coloré, ludique)?

## Affichage de données enrichies : Se poser les bonnes questions

- Hiérarchie et organisation : Comment souhaitez-vous structurer les informations pour qu'elles soient claires et accessibles ?
- Performance et fluidité : Souhaitez-vous privilégier une navigation rapide et fluide pour des sites à fort trafic ?
- Accessibilité: Y a-t-il des normes d'accessibilité que vous devez respecter?

## ÉLÉMENTS NÉCESSAIRES À L'AFFICHAGE

## Éléments nécessaires à l'affichage

- Un balisage pour l'affichage de texte dans un navigateur web :
  HTML
- Des règles pour préciser le style des diverses balises : CSS
- Une feuille de transformation pour passer d'un langage de balisage
   à l'autre : XSL(T)







## Balisage pour l'affichage de texte dans un navigateur web : HTML

- « HyperText Markup Language » qu'on peut traduire par « langage de balises pour l'hypertexte »
- Créer et représenter le contenu d'une page web et sa structure avec des « balises » pour annoter du texte, des images et d'autres contenus
- Balises insensibles à la casse et peuvent aussi bien être écrites en minuscules, en majuscules, voire avec un mélange des deux
- Trois types différents de catégories de contenu : principales qui décrivent un ensemble de règles de contenu partagées par une grande variété d'éléments ; relatives aux formulaires qui décrivent les règles de contenu partagées par les éléments en lien avec les formulaires ; spécifiques qui décrivent des catégories plus rares et qui s'appliquent à peu d'éléments, parfois dans un contexte particulier

## **HTML**: Exemple

```
<div>
 <h1>Bienvenue dans mon cours de HTML</h1>
 >
   Apprendre le HTML est <em>essentiel</em> pour comprendre la structure
des pages web.
   C'est une compétence <b>indispensable</b> pour tout développeur ou
créateur de contenu.
 >
   Avec HTML, vous pouvez créer des titres, des paragraphes, des
<em>listes, des tableaux, et bien plus encore !
 </div>
```

Ce code affiche un titre principal et deux paragraphes. Les balises <em> mettent un texte en italique et <b> le mettent en gras. Tout est organisé dans une balise <div> pour représenter une section.

## Règles pour préciser le style des diverses balises : CSS

- « Cascading Style Sheets », qu'on peut traduire par « feuilles de style en cascade »
- Langage de feuille de style utilisé pour décrire la présentation d'un document écrit en HTML ou XML, soit la façon dont les éléments doivent être affichés à l'écran, sur papier, à l'oral ou sur d'autres médias
- Gestion de la mise en forme, de la police, de la couleur, la position, l'alignement, etc. des éléments
- Différents types de sélecteurs : sélecteur d'élément, d'ID, de classe, d'attribut et de pseudo-classe

## **CSS**: Exemple

```
h1 {
  color: blue;
  text-align: center;
  font-size: 32px;
  font-family: Arial, sans-serif;
}
```

Le texte des titres H1 est bleu, centré, en taille 24 et utilise la police Arial ou une alternative sans-serif

```
p {
  color: darkgreen;
  text-align: justify;
  font-size: 18px;
  font-family: "Times New Roman",
  serif;
}
```

Le texte des paragraphes est vert foncé, justifié, en taille 13.5 et utilise la police Times New Roman ou une alternative serif

## Feuille de transformation pour passer d'un langage de balisage à l'autre : XSL(T)

- « eXtensible Stylesheet Language », qu'on peut traduire par « Langue de feuille de style extensible »
- ☐ Trois parties dans XSL : XSLT (transformation), XPath (navigation), XQuery (interrogation)
- XSLT = Transformer un document XML en un autre document XML, ou un autre type de document reconnu par un navigateur : ajouter/supprimer des éléments et des attributs vers ou depuis le fichier de sortie, réorganiser et trier les éléments, effectuer des tests et prendre des décisions sur les éléments à masquer et à afficher, et bien plus encore.

## XSLT: Exemple

Mettre une balise h1 autour de tous les éléments de titre qui sont des enfants du message

Déclarer une variable nommée « couleur », définir sa valeur sur l'attribut couleur de l'élément courant et s'il n'a pas d'attribut couleur, la valeur sera « vert »

# PANORAMA DE DIVERS MOYENS DE PUBLICATION

## Quel affichage?

- ☐ Création rapide de HTML (et CSS) : Teinte, ChatGPT, DeepSeek
- ☐ Simple affichage: GitHub Pages, CETEIcean
- Explorer une édition critique : Edition Visualization Technology (EVT),
   TEI Critical Apparatus Toolbox
- Exploiter pleinement son corpus : TEI Publisher











## Création rapide de HTML : Teinte

- Outil créé par Frédéric Glorieux en 2022 pour l'équipe ObTIC
- ☐ Plate-forme de transformation des textes électroniques en différents formats
- Formats pris en compte :
  - Input : TEI, DOCX, EPUB, MARKDOWN
  - Output: TEI, DOCX, HTML, MARKDOWN







Votre fichier

Déposer ici votre fichier

ou chercher sur votre disque...









Convertissez vos livres électroniques, de, et vers, plusieurs formats: TEI, DOCX, HTML, EPUB, MARKDOWN.

À gauche, déposez un de vos fichiers ; au centre, prévisualisez le contentu; à droite, téléchargez un export dans le format de votre choix.

Cette installation est en développement, certains chemins de conversion ne sont pas encore fonctionnels.













## **Teinte**: Exercice

- Choisissez un des fichiers XML du dossier "xml"
- Déposez-le dans la partie "Votre fichier"
- ☐ Téléchargez le HTML qui a été généré
- Ouvrez-le avec un navigateur web
- Observez le résultat

## Création rapide de HTML/CSS: IA Chatbots

- Chatbot : "Programme informatique qui simule et traite une conversation humaine (écrite ou parlée), permettant aux humains d'interagir avec des terminaux digitaux comme s'ils communiquaient avec une personne réelle"
- Large Langage Model (LLM): "Type de programme d'intelligence artificielle capable, entre autres tâches, de reconnaître et de générer du texte, après avoir été entraînés sur de vastes ensembles de données, qui s'appuient sur l'apprentissage automatique et plus spécifiquement sur un type de réseau neuronal dénommé « modèle transformateur »."
- Prompt : "Instruction destinée à une intelligence artificielle générative, ordre adressé à une machine pour qu'elle exécute ce que vous lui demandez"

Si je te soumets un fichier XML, pourras-tu me le transformer en page HTML avec CSS et tout ?

Oui, bien sûr ! Si tu me donnes un fichier XML, je peux te le transformer en une page HTML complète avec CSS (intégré ou séparé, comme tu préfères). Je peux aussi :

- interpréter la structure du XML pour en faire une présentation propre (tableaux, titres, paragraphes, etc.),
- styliser le tout pour que ce soit agréable visuellement,
- ajouter des fonctionnalités interactives si besoin (menus, boutons, etc.),
- ou encore te faire un design responsive (adapté aux mobiles).

Tu peux m'envoyer le fichier XML quand tu veux, et me préciser ce que tu veux voir dans la version HTML :

par exemple, si certains éléments doivent a $_{
m l}$   $\psi$  aître en gras, comme titres, ou s'il y a des

Poser une question



### Transformation XML en HTML avec CSS



Si je te soumets un fichier XML, pourras-tu me le transformer en page HTML avec CSS et tout ?







Absolument! Je peux vous aider à transformer un fichier XML en une page HTML stylisée avec CSS. Voici comment nous pouvons procéder :

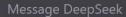
#### 1. Vous me fournissez:

- Votre fichier XML (ou son contenu)
- Vos préférences de mise en page (si vous en avez)
- Le type de rendu souhaité (tableau, cartes, liste, etc.)

#### 2. Je vous propose:

- Une structure HTML adaptée à votre XML
- Un style CSS propre et moderne





### **IA Chatbots : Exercice**

- Choisissez un des fichiers XML du dossier "xml"
- Choisissiez votre IA Chatbot ChatGPT ou DeepSeek
- Fournissez le prompt de la slide suivante en complétant les blancs selon vos envies
- Lancer le prompt
- Récupérez le fichier HTML qui a été généré
- Ouvrez le fichier dans un navigateur web
- ☐ Observez le résultat

## **IA Chatbot : Prompt**

Voici un fichier écrit en XML-TEI. Je veux que tu le transformes en un HTML que je pourrais télécharger. Le titre de l'onglet doit être le suivant "Titre Exemple". Je veux également que tu me fournisses du CSS, que tu intègres directement dans le document. Je veux un style "sobre et classique|moderne et coloré" dans les tons "bleu|rouge|jaune" avec une foliation qui apparait "souligné|barré", en taille "10|20|30" et en "rose|orange|vert". Intègres et transforme l'entièreté du contenu de l'arbre XML.

## Simple affichage: CETEIcean

- Outil créé par Raffaele Viglianti et Hugh Cayless en 2016
- Bibliothèque JavaScript permettant d'afficher des documents TEI dans un navigateur
   Web sans les transformer au préalable en HTML
- Test possible depuis le GitHub : <a href="https://github.com/TEIC/CETEIcean">https://github.com/TEIC/CETEIcean</a>

### **Introducing CETEIcean**

CETEIcean is a Javascript library that lets you display Text Encoding Initiative (TEI) or other XML files directly in your browser. You can style them using ordinary CSS or add <u>behaviors</u> to them. CETEIcean does not throw away any information in the source file, meaning you can take full advantage of the TEI (or DocBook, etc.) data model to add useful features to your document.



### **Getting Started**

Check out the examples. Most of these are based on the <u>testTEI.xml</u> file.

- A simple test.
- addBehaviorTest shows how to add your own behaviors.
- <u>EEBOTest</u> imports a remote TEI File from the <u>EEBO project</u> and styles it. If you can log in to the Chadwyck EEBO site, then you will be able to see page images.
- TCW22 is an example of a TEI Technical Council Working Paper, pulling from the live source on GitHub.
- A DocBook example. Our 2018 Balisage paper.

Note that if you want to display remote XML documents, the server where they are located must support <u>CORS</u>. Otherwise, you're stuck with documents on the same server. Fortunately and usefully, GitHub does enable CORS, so you can use CETEIcean with any TEI file in a GitHub repo!

The GitHub repo lives at <u>TEIC/CETEIcean</u>. Please let us know if you find bugs or think of new features you'd like to see!

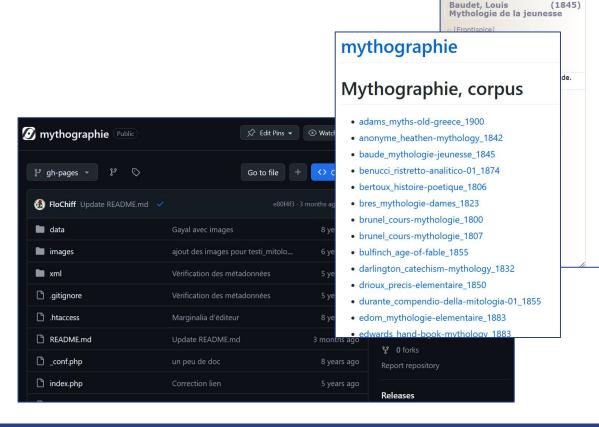
## Simple affichage: GitHub Pages

- Outil créé par l'équipe GitHub en 2008
- Service d'hébergement de sites statiques qui récupère les fichiers HTML, CSS et JavaScript directement à partir d'un référentiel sur GitHub, exécute éventuellement les fichiers via un processus de construction et publie un site Web
- Pour en créer une : Settings > Pages > Branch (choisir sa branche et son dossier de documents à publier)

## Websites for you and your projects.

Hosted directly from your GitHub repository. Just edit, push, and your changes are live.





#### Le Chaos. — Formation du monde. — Les quatre âges.

Avant la formation du monde, il n'existait que le *Chaos*, assemblage confus de tous les éléments. Le soleil et la lune n'éclairaient pas ; la terre n'était point suspendue au milieu de l'espace, et la mer était sans rivages. Le froid et le chaud, le sec et l'humide, les corps pesants et les corps légers se livraient une guerre perpétuelle. Un dieu inconnu mit fin à ce désordre, en marquant à chaque élément la place qu'il devait occuper et en assujettissant la nature aux lois d'une immuable harmonie. Le Chaos cessa d'exister<sup>3</sup>.

C'est alors que parurent le soleil, la lune, les étoiles, les animaux de l'air, de la terre et des mers, et enfin l'homme.

On vit d'abord fleurir l'innocence et la justice. La terre produisait sans culture, et des fleuves de lait et de miel coulaient de toutes parts. C'était l'âge d'or<sup>4</sup> [Fig. 7].

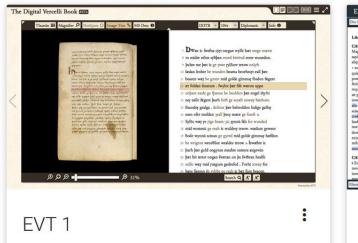


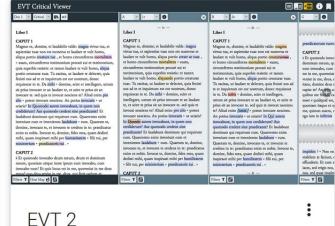
## Explorer son édition critique: EVT

- Outil créé en 2013 par des étudiants de l'Université de Pise dans le contexte du <u>Digital</u>
   <u>Vercelli Book project</u>
- Outil léger et open source spécialement conçu pour créer des éditions numériques à partir de textes codés en XML, permettant à l'utilisateur final de parcourir, d'explorer et d'étudier les éditions numériques au moyen d'une interface conviviale.
- Deux versions existent : EVT 1 et EVT 2

#### **Edition Visualization Technology**

A light-weight, open source tool specifically designed to create digital editions from XML-encoded texts, freeing the scholar from the burden of web programming and enabling the final user to browse, explore and study digital editions by means of a user-friendly interface.





# Explorer son édition critique : TEI CAT

- Outil créé par Marjorie Burghart en 2016
- Visualisation aisée pour les éditions critiques XML TEI, particulièrement pour des éditions nativement numériques, dont l'objectif principal est de fournir aux éditeurs un moyen simple de visualiser leur travail en cours avant sa finalisation, et d'effectuer des contrôles qualité automatiques sur leur encodage
- Tâches disponibles : Afficher l'édition, effectuer des contrôles de qualité sur l'encodage, afficher le texte d'un ou plusieurs témoins spécifiques, obtenir un PDF imprimable et/ou un fichier LaTeX à partir d'un fichier XML TEI, annoter une image en XML TEI, obtenir des statistiques de base sur votre fichier TEI



### **TEI Critical Apparatus Toolbox**

Check your encoding Display parallel versions Print an edition Annotate an image Get statistics Help Download Credits

The TEI Critical Apparatus Toolbox is a tool for people preparing a natively digital TEI critical edition.

#### The Toolbox lets you

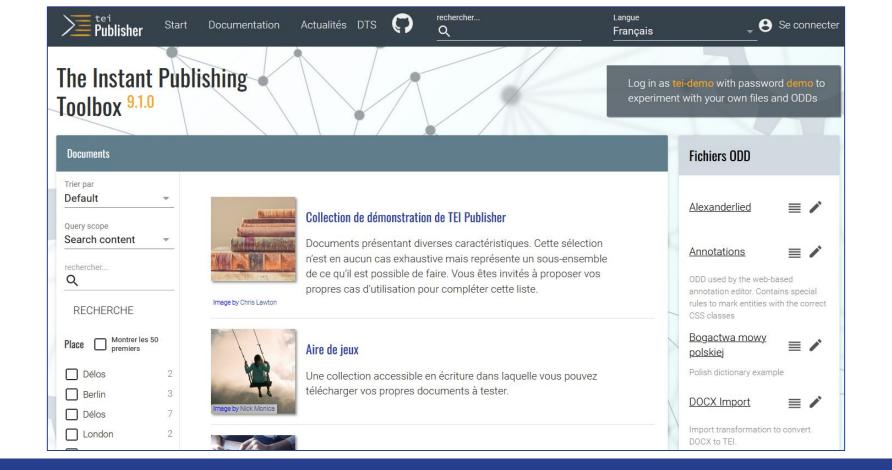
- Check your encoding: offers facilities to display your edition while it is still in the making, and check the consistency of your encoding
- Display parallel versions: choose the sigla of the witnesses, and the different versions of the text, following each chosen witness, will be displayed in parallel columns.
- Print an edition of a TEI XML edition, with a TEI-to-LateX and PDF transformation
- Annotate an image: lets you easily trace zones on an image to prepare a documentary edition
- Get statistics on the XML tags effectively used in different parts of your edition, and some word count.

## **TEI CAT**: Exercice

- Afficher les versions parallèles : Récupérer le fichier <u>Lucain.xml</u>, le soumettre, cocher Critical Text et 3 témoins, le soumettre, observer le résultat
- Imprimer une édition : Adapter le layout (10pt, 0.5), la langue (français), les titres tei:head (LARGE, 0.5, center), ajouter un fichier XML du dossier "xml", appuyer sur Envoyer, ouvrir le dossier zippé et le PDF dedans, observer le résultat
- Obtenir des statistiques : Ajouter un fichier XML depuis le dossier "xml", le soumettre, observer le résultat

### Exploiter pleinement son corpus : TEI Publisher

- Outil initié en 2015 et concrétisé à partir de 2020 par l'équipe e-editiones
- Fournir un outil qui permet aux chercheurs et aux éditeurs de publier leurs documents sans devenir des programmeurs, mais qui ne les force pas non plus à adopter un cadre unique
- Proposition de **templates HTML** et de **fichier ODD de transformation** pour des collections de fichiers XML, et possibilité de générer une **instance personnalisée**



# Instances réalisées par l'équipe TEI Publisher à titre d'exemples

- Hébergé par TEI Publisher sur leur serveur
- Diversité des documents
  - Lettres
  - Pièces de théâtre
  - Rapports
  - Livres



When the Wall Came Down



Van Gogh Letters

- Design générique, aucune autre page d'accueil
  - ☐ Deux avec un CSS par défaut
  - Deux avec un CSS personnalisé
- Accès à des options intéressantes
  - Langage
  - Filtres







Early English Books

# Instances créées par des DH et autres

- → Hébergé par un serveur externe (Huma-Num ou l'University de Genève)
- Diversité de documents
  - Lettres
  - Chapbooks
  - Écrits

- Design personnalisée
- Accès à des options intéressantes
  - Plusieurs collections dans la même instance
  - ☐ Informations complémentaires fournies (ressources, à propos, etc.)







**Antonomaz** 

Desenrollando el cordel

I must tell you that even while working I

Je dois vous dire que meme pendant le



SÉNAT

NEW YORK, 28th of July 1919.

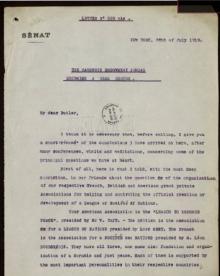
THE CARNEGIE ENDOWMENT BUREAU BECOMING A REAL CENTRE.

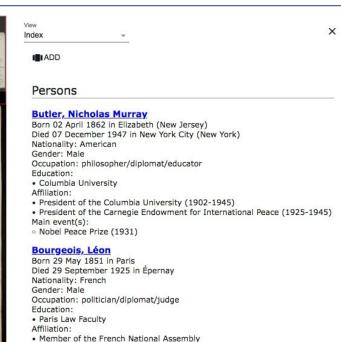
My dear Butler,

I think it is necessary that, before sailing, I give you a short "résumé" of the conclusions I have arrived at here, after many conferences, visits and meditations, concerning some of the principal questions we have at heart.

First of all, here is what I told, with the most deep conviction, to our friends about the question of the organisation of our respective French, British and American great private Associations for helping and controlling the official creation or development of a League or Société of Nations.

Your American Association is the "LEAGUE TO ENFORCE PEACE", presided by Mr W. TAFT. - The British is the Association for a LEAGUE OF NATIONS presided by Lord GREY. The French is the Association for a SOCIÉTÉ des NATIONS presided by M. Léon BOURGEOIS. They have all three, one same aim: fundation and organ-ization of a durable and just peace. Each of them is supported by the most important personalities in their respective countries;





Member of the Académie des Sciences Morales et Politiques and th

. Senator of the French Third Republic

President of the Council
 Prefect of Police of Paris

#### Bogactwa mowy polskiej — Laboratorium Leksykograficzne ks. Alojzego Osińskiego





#### kształt drobnych kamyczków, dziarstwisty:/

t. 867 p. 3/3

Glina karnyczkowatá Eligner

Piasek kamyczkowaty Trzeci And

#### Kamyk, im. zdrob. kamienia /:mały kamień:/

Chrusnął kamyk między zębami Birkow

Trze nogę kamyk Tenże

Uciska nogę kamyk Tenże

Wlazł w trzewik kamyk Tenże

Kamyk biały Bud Szy

— cisnięty na wodę Feliń

- probierny Niemoio Jan

#### Kamyszczek, im. zdrob kamienia /:kamyczek:/

Liczyła pacierze swé kamyszczkami Skarga

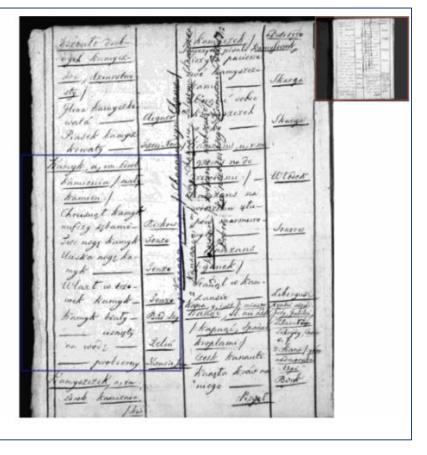
Wtrącać sobie kamyszczek w oko Skarga

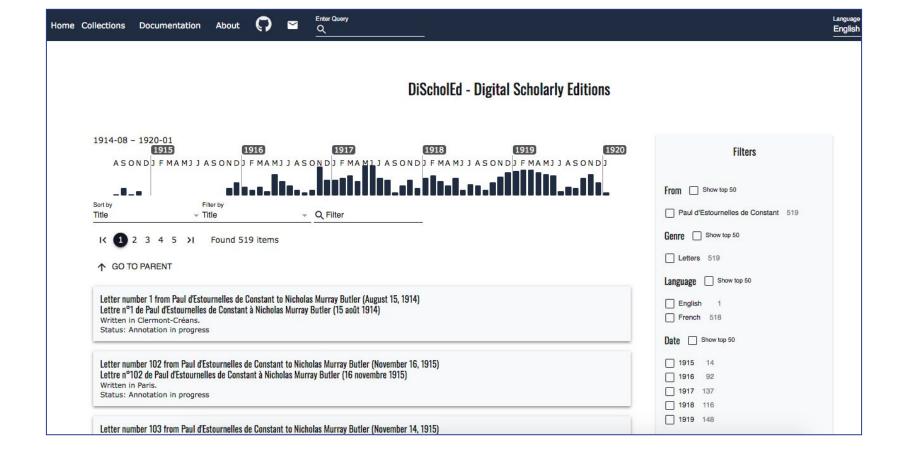
#### Kamzans, u, r. m /:gzems nade drzwiami:/ Włodek

Kamzans na wieszchu słupów marmurowych Starow

Kanaan, a, m, i. /: Chanaan, syn Chama:/

2. Kanaan, u, r. m /:kráy Chanaana, Palestyna Channanea Kanaan:/ /:królestwo





### **TEI Publisher**: Exercice

- ☐ Se connecter avec les identifiants suivants : *tei-demo* et *demo*
- Aller dans Aire de jeux > Ajouter un fichier XML > Une fois dans le fichier, appuyer sur les trois lignes horizontales en haut en droite > Choisir diverses ODD/HTML et observer le résultat
- Créer une ODD dans "Fichiers ODD" > Ajouter l'élément persName et mettre dans Renditions "color: red;" et faire de même avec placeName mais en vert
- Aller dans Fonctions avancées > Générateur d'application > Observer ce qui est proposé

# **RESSOURCES**

### **Ressources: Sites Web**

- ChatGPT: <a href="https://chatgpt.com/">https://chatgpt.com/</a>
- DeepSeek : <a href="https://chat.deepseek.com/">https://chat.deepseek.com/</a>
- Edition Visualization Technology: <a href="http://evt.labcd.unipi.it/">http://evt.labcd.unipi.it/</a>
- ☐ GitHub Pages : <a href="https://pages.github.com/">https://pages.github.com/</a>
- TEI Publisher : <a href="https://teipublisher.com/exist/apps/tei-publisher/index.html">https://teipublisher.com/exist/apps/tei-publisher/index.html</a>
- TEI Critical Apparatus Toolbox : <a href="http://teicat.huma-num.fr/">http://teicat.huma-num.fr/</a>
- ☐ Teinte: <a href="https://obtic.huma-num.fr/teinte/">https://obtic.huma-num.fr/teinte/</a>

### **Ressources: Sites Web**

- CETEIcean : <a href="https://teic.github.io/CETEIcean/">https://teic.github.io/CETEIcean/</a>
- CSS: <a href="https://developer.mozilla.org/fr/docs/Web/CSS">https://developer.mozilla.org/fr/docs/Web/CSS</a>
- GitHub : <a href="https://github.com/">https://github.com/</a>
- ☐ HTML : <a href="https://developer.mozilla.org/fr/docs/Web/HTML">https://developer.mozilla.org/fr/docs/Web/HTML</a>
- Nakala : <a href="https://www.nakala.fr/">https://www.nakala.fr/</a>
- XSLT: <a href="https://www.w3schools.com/xml/xsl\_intro.asp">https://www.w3schools.com/xml/xsl\_intro.asp</a>
- Zenodo : <a href="https://zenodo.org/">https://zenodo.org/</a>

### **Ressources: Publications**

- Alix Chagué, Floriane Chiffoleau, Matthias Gille Levenson, Hugo Scheithauer, Ariane Pinche. *Chaînes d'acquisition, de traitement et de publication du texte*. Consortium Ariane Axe 1. 2024 : <a href="https://hal.science/hal-04734959">https://hal.science/hal-04734959</a>
- □ Floriane Chiffoleau. *TEI Publisher, a platform for sustainable digital editions*. 2023 : <a href="https://hal.science/hal-04247980">https://hal.science/hal-04247980</a>
- □ Elena Pierazzo, What future for digital scholarly editions? From Haute Couture to Prêt-à-Porter, International Journal of Digital Humanities, 2019, <a href="https://doi.org/10.1007/s42803-019-00019-3">https://doi.org/10.1007/s42803-019-00019-3</a>

# Merci de votre attention

Des questions?

<u>https://github.com/FloChiff/</u>
<u>AtelierObTIC-creer-une-edition-scientifique-numerique</u>
chiffoleau.floriane[at]gmail.com